

Outils mathématiques pour l'Analyse de Données

Révision

Chargé du cours
Prof. Mustapha Rachdi



Université Grenoble Alpes
Bât. Michel Dubois
UFR SHS, BP. 47
38040 Grenoble cedex 09
France
Bureau : C08 au Bât. Michel Dubois
e-mail : mustapha.rachdi@univ-grenoble-alpes.fr



- Quel type d'information ?
 - Tableau de contingence \implies AFC : CA
 - Tableau individus-variables \implies il faut faire un choix de la méthode (cf. point 3)
- Éléments actifs ? Quels éléments participeront à la construction des axes factoriels ?
`ind.sup`, `quantif.sup`, `qualif.sup`, `row.sup`, `col.sup`
- Nature des variables actives ?
 - Quantitative \implies ACP : PCA
 - Qualitative \implies
 - s'il n'y a que 2 variables , construire le tableau croisé \implies AFC : CA
 - sinon \implies AFCM : MCA
- Si ACP, faut-il réduire les variables ?
oui \implies ACP réduite : `scale.unit = TRUE`
- Y a-t-il des données manquantes ?
si oui \implies utiliser le package `missMDA` pour compléter le jeu de données

Une fois qu'on a décidé de la méthode à utiliser

- Lancer l'analyse factorielle : `PCA`, `CA`, ou `MCA`
- Voir les résultats et construire les graphes : `summary`, `plot`
- Décrire les axes factoriels par les variables initiales : `dimdesc`
- Faire une classification des individus et décrire les classes : `HCPC`

Quelques extensions que l'on va étudier

- Lorsque certaines variables sont quantitatives et d'autres qualitatives. Comment faire pour qu'elles soient toutes actives ?
 - Découper les variables quantitatives en classes puis ACM
 - Analyse factorielle des données mixtes : FAMD
- Lorsque les données sont structurées en groupes : plusieurs groupes de variables *quantitatives* ou *qualitatives* ou des *tableaux de contingence* \implies Analyse factorielle multiple : MFA

Généralités sur les matrices

Ce chapitre rassemble des rappels d'algèbre linéaire utiles à la statistique multidimensionnelle. Les résultats seront énoncés sans démonstration.

Définition

On appelle A , matrice d'ordre (n, p) et de terme général a_{ij} , un tableau rectangulaire à n lignes et p colonnes :

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \cdot & \cdot & \dots & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ a_{n1} & a_{n2} & \dots & a_{np} \end{pmatrix}$$

Exemple

$$A = \begin{pmatrix} 1 & 0 & 2 & 8 \\ 3 & 1 & 2 & 0 \\ 5 & 7 & 6 & 9 \end{pmatrix} \text{ matrice d'ordre } (3, 4).$$

Cas particuliers

- Si $n = 1$, A est appelée *vecteur-ligne*.
- Si $p = 1$, A est appelée *vecteur-colonne*.
- Si $n = p$, A est appelée *matrice carrée* d'ordre n .

Exemple

$$A = \begin{pmatrix} 1 & 5 & 3 \\ 2 & 4 & 1 \\ 7 & 2 & 8 \end{pmatrix} \text{ matrice carrée d'ordre } 3$$

Définition

Les vecteurs sont dits linéairement indépendants si la seule combinaison linéaire de ces vecteurs qui soit nulle est la combinaison linéaire nulle.

Définition

Le rang d'une matrice A d'ordre (n, p) est le nombre maximum de vecteurs-colonne de A linéairement indépendants. C'est aussi le nombre maximum de vecteurs-ligne de A linéairement indépendants.

Addition de matrices

Définition

Soient A et B deux matrices de même ordre $A = (a_{ij})$ et $B = (b_{ij})$, on pose :

$$A + B = (a_{ij} + b_{ij}).$$

Exemple

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 5 \\ 4 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & -1 \\ 5 & 6 \\ 3 & 4 \end{pmatrix}, \quad A + B = \begin{pmatrix} 1 & 1 \\ 8 & 11 \\ 7 & 4 \end{pmatrix}.$$

Propriété

L'addition de deux matrices est associative et commutative :

$$A + (B + C) = (A + B) + C \text{ et } A + B = B + A.$$

Définition

Soit λ un scalaire et A une matrice d'ordre (n, p) , alors

$$\lambda A = \lambda(a_{ij}) = (\lambda a_{ij}).$$

Soit $B = (b_{ij})$ une matrice d'ordre (p, q) , le produit AB est défini comme étant la matrice $C = (c_{ij})$ d'ordre (n, q) dont les éléments sont donnés par

$$c_{ij} = \sum_{k=1}^p a_{ik} b_{kj}.$$

Pour que le produit de deux matrices soit possible, il faut que le nombre de colonnes de celle de gauche soit égal au nombre de lignes de celle de droite.

Multiplication de matrices et transposée : $\otimes \star \otimes$ et t

Exemple

$$A = \begin{pmatrix} 1 & 4 & 2 \\ 0 & 1 & 3 \end{pmatrix}, B = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 0 \\ 0 & -1 & 2 \end{pmatrix}, AB = \begin{pmatrix} 1 & 2 & 3 \\ 0 & -2 & 6 \end{pmatrix}.$$

Propriété

La multiplication de matrices est associative mais non commutative :

$$A(BC) = (AB)C, (A+B)C = AC + BC, A(B+C) = AB + AC.$$

Définition

Soit A une matrice d'ordre (n, p) , on appelle matrice transposée (tA) de A la matrice d'ordre (p, n) dont les colonnes sont les lignes de A .

Propriété

$$^t(A+B) = ^tA + ^tB \quad \text{et} \quad ^t(AB) = ^tB^tA$$

Trace d'une matrice carrée

Définition

Soit A une matrice carrée d'ordre n de terme général a_{ij} , la trace de A , notée $\text{Trace}(A)$ est la somme de ses éléments diagonaux :

$$\text{Trace}(A) = \sum_{i=1}^n a_{ii}.$$

Exemple

Si $A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix}$, alors $\text{Trace}(A) = 15$.

Propriété

- $\text{Trace}(\lambda A) = \lambda \text{Trace}(A)$.
- $\text{Trace}(A + B) = \text{Trace}(A) + \text{Trace}(B)$.
- $\text{Trace}(AB) = \text{Trace}(BA)$.

Déterminant des matrices carrées d'ordres 2 et 3

- Soit A une matrice carrée d'ordre 2,

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}.$$

Le déterminant est le scalaire noté $\det(A)$ ou $|A|$, tel que

$$\det(A) = a_{11}a_{22} - a_{12}a_{21}.$$

- Soit A une matrice carrée d'ordre 3,

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}.$$

Le déterminant de A est donné par :

$$\begin{aligned} \det(A) = & a_{11}a_{22}a_{33} + a_{21}a_{32}a_{13} + a_{31}a_{12}a_{23} \\ & - a_{13}a_{22}a_{31} - a_{23}a_{32}a_{11} - a_{33}a_{12}a_{21}. \end{aligned}$$

Déterminant des matrices carrées d'ordres 2 et 3

Exemple

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix}$$

$$\det(A) = -2 \text{ et } \det(B) = 0.$$

Nous ne donnons pas ici le calcul du déterminant d'une matrice d'ordre n ($n > 3$).

Déterminants et inverses des matrices carrées : `det` et `solve`

Propriété

- $\det(AB) = \det(A) \det(B)$.
- $\det(I_n) = 1$.
- Si D_n est diagonale d'éléments diagonaux (d_{ii}) , alors
$$\det(D_n) = \prod_{i=1}^n d_{ii}.$$
- $\det({}^tA) = \det(A)$.
- $\det(A) \neq 0$ si, et seulement si, A est inversible.
- Si A est inversible, alors $\det(A^{-1}) = (\det(A))^{-1}$.

Valeurs propres et vecteurs propres : `eigen$values` et `eigen$vectors`

Définition

Soit A une matrice carrée. On dit que u est un vecteur propre de A , si :

- u est différent de zéro (le vecteur nul).
- il existe λ scalaire, tel que $Au = \lambda u$.

Le scalaire λ est appelé la valeur propre de A associée à u . Le vecteur u est également dit vecteur propre associé à la valeur propre λ .

Propriété

- Si λ est une valeur propre de A , alors λ est racine de $\det(A - \lambda I_n)$, qui est un polynôme de degré n .
- Si u vecteur propre associé à la valeur propre λ , alors $Au = \lambda u$.
- Si λ_i pour $i = 1, \dots, m$ désignent les valeurs propres de la matrice A , alors
$$\sum_{i=1}^m \lambda_i = \text{Trace}(A).$$

Matrices réelles symétriques

Définition

Une matrice carrée est symétrique, si elle est égale à sa transposée.

Exemple

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 0 & 4 \\ 3 & 4 & 8 \end{pmatrix} = {}^tA.$$

Remarque

Le produit d'une matrice par sa transposée donne une matrice symétrique.

Les matrices tAA et $A{}^tA$ sont symétriques même si A n'est pas symétrique.

Propriété

Soit A une matrice réelle symétrique, alors :

- *A est diagonalisable.*
- *Les valeurs propres de A sont toutes réelles. .*
- *Si x et y sont deux vecteurs propres, alors*

$${}^t x A y = {}^t y A x.$$

Matrices définies positives

Définition

Une matrice réelle symétrique M est dite définie positive si

$${}^tX M X > 0, \text{ pour tout vecteur } X \text{ non nul.}$$

Théorème

Une matrice M est définie positive si, et seulement si, toutes ses valeurs propres sont strictement positives.

Théorème

Une matrice réelle symétrique A est définie positive si et seulement si il existe une matrice non singulière C telle que $A = C^t C$.

Théorème

Si A est une matrice non singulière, alors ${}^tA A$ est définie positive.

Définition

Une métrique est une matrice symétrique définie positive.

Remarque

La matrice identité I_n est une métrique, d'autres exemples seront donnés plus loin.

Norme

Dans toute la suite M désigne une métrique.

Définition

On appelle norme sur un espace vectoriel E , une application de E dans \mathbb{R}_+ , telle que

$$x \mapsto \|x\|$$

et vérifiant les propriétés suivantes :

- $\|x\| = 0 \iff x = 0$.
- $\|ax\| = |a| \|x\|$ pour tout scalaire a et tout x de E .
- $\|x + y\| \leq \|x\| + \|y\|$ pour tout x et y de E (inégalité triangulaire).

Définition

Soit x un vecteur, sa norme est définie par

$$\|x\|_M = \sqrt{x M x}.$$

Un vecteur est dit normé si et seulement si sa norme vaut 1.

Définition

Soient x et y deux vecteurs et M une métrique.

- Leur produit scalaire, relativement à M , est défini par :

$$\langle x, y \rangle_M = {}^t x M y.$$

La notation $\langle \cdot, \cdot \rangle_M$ permet de préciser la métrique utilisée.

- La distance entre x et y est définie par $d(x, y) = \|x - y\|_M$.
- Le vecteur x est M -orthogonal à y si, et seulement si, ${}^t x M y = 0$.
- Le cosinus de l'angle α formé par ces vecteurs est donné par :

$$\cos(\alpha) = \frac{\langle x, y \rangle_M}{\|x\|_M \|y\|_M}.$$

Projecteur et projection

Définition

On appelle projecteur une métrique idempotente.

Exemple

La matrice nulle et la matrice identité sont des projecteurs.

Définition

*Soit x un vecteur quelconque et \mathcal{D}_u la droite engendrée par le vecteur u .
Le point*

$$x_h = \frac{{}^t x M u}{\|u\|} u$$

est la projection orthogonale du point x sur \mathcal{D}_u .

Définition

Une application $g : \mathbb{R}^n \times \mathbb{R}^n \longrightarrow \mathbb{R}$, est dit une forme bilinéaire si, et seulement si, pour tout $(u, v, w) \in \mathbb{R}^3$ et pour tout $\lambda \in \mathbb{R}$:

$$g(u + v, w) = g(u, w) + g(v, w)$$

$$g(u, v + w) = g(u, v) + g(u, w)$$

$$g(\lambda u, v) = g(u, \lambda v) = \lambda g(u, v)$$

A toute forme bilinéaire, on peut associer une matrice M , telle que :

$$g(u, v) = {}^t u M v$$

Définition

Une forme bilinéaire g est dite symétrique si et seulement si, pour tout $u, v \in \mathbb{R}^n$:

$$g(u, v) = g(v, u).$$

Remarque

Si g est symétrique, alors la matrice M associée à g est symétrique.

Définition

On appelle forme quadratique associée à la forme bilinéaire g , l'application

$$g : \begin{array}{ccc} \mathbb{R}^n & \longrightarrow & \mathbb{R} \\ u & \longmapsto & f(u) = g(u, u) = {}^t u M u \end{array}$$

M étant une matrice carrée de dimension n , qui s'écrit $(M_{ij})_{1 \leq i, j \leq n}$ avec $M_{ij} = M_{ji}$.

Donc

$${}^t u M u = \sum_{i=1}^n u_i^2 M_{ii} + 2 \sum_{i=1}^n \sum_{i < j} u_i M_{ij} u_j$$

Formes quadratiques

Formes quadratiques définies positives La forme quadratique ${}^t u M u$ est définie positive si, pour tout vecteur $u \in (\mathbb{R}^n)^*$,

$${}^t u M u > 0.$$

Formes quadratiques semi-définies positives La forme quadratique ${}^t u M u$ est semi-définie positive si, pour tout vecteur $u \in (\mathbb{R}^n)^*$,

$${}^t u M u \geq 0.$$

Tableau de données multidimensionnelles

En général les observations de p variables sur n individus sont présentées sous la forme d'une matrice X d'ordre (n, p) de terme général x_i^j où x_i^j désigne la valeur prise par la variable numéro j sur l'individu numéro i .

Exemple

$$X = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \text{ et } X_2 = \begin{pmatrix} 0 \\ 2 \\ 0 \end{pmatrix}$$

- Chaque variable X_j est considérée comme un vecteur d'un espace à n dimensions appelé *espace des variables*.
- De même, chaque individu noté e_i est un élément d'un espace vectoriel appelé *espace des individus*.

Matrice de poids

Définition

On supposera qu'à chaque individu e_i est associé un poids p_i positif tel que $\sum_{i=1}^n p_i = 1$.

On notera $D_n = \begin{pmatrix} p_1 & & 0 \\ & \ddots & \\ 0 & & p_n \end{pmatrix}$ la matrice diagonale de poids.

Définition

Soit $\mathbb{I}_n = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$ le vecteur dont les n composantes sont égaux à 1. Le centre de gravité du nuage des individus est le vecteur : $g = {}^tX D_n \mathbb{I}_n$.

Matrice de variance-covariance et de corrélation

Définition

La matrice de variance-covariance V est définie par :

$$V = {}^tX D_n X - g {}^t g.$$

Si les poids sont centrés i.e., $g = 0$, alors la matrice de variance-covariance devient :

$$V = {}^tX D X$$

Remarque

La matrice de variance-covariance est une matrice carrée et symétrique.

Définition

Si on note $D_{1/s}$ la matrice diagonale des inverses des écart-types, la matrice de corrélation, notée R est définie par

$$R = D_{\frac{1}{s}} V D_{\frac{1}{s}}.$$

Utilisation de la métrique statistique

- Pour mesurer la distance entre individus ou entre variables, il faut définir un produit scalaire, donc une métrique.
- La métrique que l'on utilise dans le cas de variables, est la matrice des poids D_n .
- Pour mesurer la proximité entre individus, on utilise une des métriques suivantes :
 - la métrique euclidienne classique : c'est le cas où $M = I_n$, c'est-à-dire celle qui revient à utiliser le produit scalaire usuel. Par conséquent, on a la distance euclidienne :

$$d^2(x, y) = \sum_i (x_i - y_i)^2.$$

- La métrique de Mahalanobis correspond à $M = V^{-1}$.